



UFC

Universidade Federal do Ceará

Tema geral

Nesta avaliação, cada equipe deverá desenvolver um estudo prático de aprendizado não supervisionado utilizando um dataset fornecido pelo professor. O objetivo é explorar os dados, investigar padrões naturais, aplicar técnicas de clusterização, comparar algoritmos e analisar o impacto do pré-processamento e da redução de dimensionalidade. A equipe deverá produzir um código organizado (não pode ser colab), com gráficos e/ou saída tabulares, para cada questão.

Dataset

Cada equipe receberá um dataset com atributos numéricos e uma variável de referência categórica.

Questão 1 – Análise Exploratória dos Dados

Realize uma análise exploratória inicial do dataset.

A equipe deverá apresentar:

1. Descrição geral do dataset:
2. Verificação de problemas nos dados
3. Estatísticas descritivas
4. Visualizações exploratórias:

A equipe deverá interpretar os principais achados da análise exploratória, destacando quais atributos parecem mais relevantes para uma possível análise de agrupamento.

Questão 2 – Análise Visual com Dois Atributos

Escolha dois atributos numéricos do dataset e investigue visualmente se existe possibilidade de formação de clusters naturais.

A equipe deverá:

1. Justificar a escolha dos dois atributos.
2. Criar um gráfico de dispersão entre os dois atributos.
3. Observar se há separação visual entre possíveis grupos.
4. Caso exista uma variável categórica de referência, colorir os pontos por essa variável apenas para fins de análise visual.
5. Discutir se os dois atributos escolhidos parecem suficientes para representar a estrutura dos dados.

A resposta deverá conter uma análise crítica. A equipe deve indicar se a clusterização visual parece viável ou se será necessário utilizar mais atributos.

Questão 3 – Clusterização com K-Means e Escolha do Melhor K

Aplique o algoritmo K-Means utilizando um conjunto maior de atributos.

A equipe deverá:

1. Selecionar os atributos que serão utilizados na clusterização.
2. Justificar a escolha desses atributos.
3. Aplicar pré-processamento quando necessário.
4. Testar diferentes valores de K.
5. Utilizar o método do cotovelo para analisar a variação da inércia.
6. Utilizar o Silhouette Score para comparar os valores de K.
7. Escolher o melhor valor de K com base nos resultados obtidos.
8. Treinar o K-Means com o melhor K escolhido.
9. Visualizar os clusters obtidos em gráficos 2D, utilizando:
 - Os dois atributos mais relevantes.

Usando a variável categórica de referência, a equipe deverá criar uma tabela cruzada (crosstab) entre os clusters gerados e a variável real.

A equipe deverá interpretar a tabela cruzada, analisando se os clusters encontrados possuem alguma correspondência com as categorias reais do dataset.

Questão 4 – Comparação entre K-Means e DBSCAN

Aplique o algoritmo DBSCAN ao mesmo conjunto de dados utilizado na questão anterior.

A equipe deverá:

1. Explicar brevemente a diferença entre K-Means e DBSCAN.
2. Escolher valores adequados para os parâmetros:
 - `eps`
 - `min_samples`
3. Justificar como esses parâmetros foram definidos.
4. Aplicar o DBSCAN.
5. Identificar:
 - Quantidade de clusters encontrados.
 - Quantidade de pontos considerados ruído.
6. Visualizar os agrupamentos gerados.
7. Comparar os resultados com o K-Means.

A comparação deverá considerar:

- Quantidade de clusters.
- Presença de ruídos.
- Formato dos agrupamentos.
- Sensibilidade à escala dos atributos.
- Facilidade de interpretação.
- Relação com a variável categórica de referência

A equipe deverá concluir qual algoritmo apresentou resultado mais coerente para o dataset analisado.

Questão 5 – Impacto da Normalização na Clusterização

Investigue se a normalização dos dados melhora a qualidade da clusterização.

A equipe deverá comparar pelo menos duas situações:

1. Clusterização sem normalização.
2. Clusterização com normalização.

A equipe poderá testar técnicas como:

- Z-score, usando `StandardScaler`.
- Min-Max, usando `MinMaxScaler`.
- Transformação logarítmica, caso existam atributos com forte assimetria e valores positivos.

A equipe deverá aplicar novamente os algoritmos de clusterização após a normalização e comparar os resultados.

A análise deverá considerar:

- Mudança nos gráficos de dispersão.
- Mudança no melhor valor de K.
- Mudança no Silhouette Score.
- Mudança na distribuição dos clusters.
- Mudança na tabela cruzada
- A equipe deverá responder: a normalização ajudou, prejudicou ou não alterou significativamente a clusterização? Justifique com base nos resultados.

Questão 6 – Clusterização Hierárquica e Dendrograma

Aplice técnicas de clusterização hierárquica para analisar a associação entre as amostras e os possíveis grupos do dataset.

A equipe deverá:

1. Selecionar os atributos utilizados para a clusterização hierárquica.
2. Aplicar uma técnica de normalização, se necessário.
3. Gerar um dendrograma.
4. Testar diferentes métodos de ligação, como:
 - complete
 - average
 - single
5. Analisar visualmente o dendrograma.
6. Indicar uma possível quantidade de clusters com base no corte do dendrograma.
7. Comparar o número de clusters sugerido pelo dendrograma com o valor de K escolhido no K-Means.

A equipe deverá discutir se a clusterização hierárquica confirma ou contradiz os resultados obtidos anteriormente.

Questão 7 – Redução de Dimensionalidade com PCA e Comparar em Classificação sem PCA

Aplice PCA para redução de dimensionalidade e avalie o impacto dessa redução em um processo de classificação supervisionada.

Atenção: nesta questão, a variável-alvo categórica poderá ser utilizada para treinar e avaliar modelos de classificação. Essa etapa tem o objetivo de verificar se a redução dimensional preserva informações úteis para classificação.

A equipe deverá:

1. Separar atributos de entrada e variável-alvo.
2. Aplicar pré-processamento quando necessário:
 - Z-score.

- Min-Max.
 - Transformação logarítmica, se fizer sentido.
3. Aplicar PCA nos atributos de entrada.
 4. Treinar um modelo de classificação com os dados originais.
 5. Treinar o mesmo modelo de classificação com os dados reduzidos via PCA.
 6. Comparar os resultados e verificar se vale a pena neste caso realizar algum processo de redução de dimensionalidade.

A equipe poderá utilizar algoritmos como :

- KNN.
- Regressão Logística.(opcional)
- Árvore de Decisão..(opcional)
- Random Forest..(opcional)
- SVM..(opcional)

A comparação deverá considerar métricas como:

- Acurácia.
- Precisão.
- Recall.
- F1-score.
- Matriz de confusão.

Critérios de Avaliação

Critério	Pontuação
Análise exploratória dos dados	0,5
Análise visual com dois atributos	0,5
K-Means, escolha do K, cotovelo, Silhouette Score e crosstab	2
Comparação entre K-Means e DBSCAN	2
Análise do impacto da normalização	1
Clusterização hierárquica e dendrograma	1
PCA e comparação com classificação supervisionada	2
Organização, interpretação crítica e qualidade do código	1

Total	10,0
--------------	-------------

Datasets

Abimael e Kaue

<https://archive.ics.uci.edu/dataset/352/online+retail>

Angelo Justino

<https://archive.ics.uci.edu/dataset/292/wholesale+customers>

Antonio, Kevin e Ramon

<https://www.kaggle.com/datasets/arjunbhasin2013/ccdata/data>

Dayne, Suiany e Cecília

<https://archive.ics.uci.edu/dataset/222/bank%2Bmarketing>

Hellen e Gabriela

<https://www.archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones>

Kelsey e Matias

<https://archive.ics.uci.edu/dataset/270/gas%2Bsensor%2Barray%2Bdrift%2Bdataset%2Bat%2Bdifferent%2Bconcentrations>

Maria de Fatima e Elyson

<https://www.kaggle.com/datasets/dgomonov/new-york-city-airbnb-open-data/>